# Organizzazione degli Elaboratori

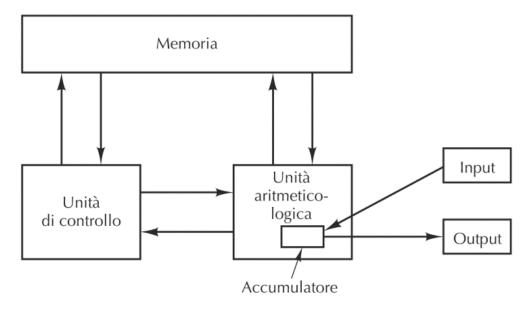


Figura 1.5 La macchina originale di von Neumann.

Prof. Ivan Lanese

# Entriamo dentro all'architettura di un tipico calcolatore moderno

- Un calcolatore è un sistema composto da processori, memorie e dispositivi di input/output (I/O)
- Questa organizzazione (con l'unica differenza del bus) è uguale a quella della macchina di Von Neumann
- Organizzazione "bus oriented": Un bus è un insieme di connessioni elettriche (fili) parallele utilizzati per trasportare informazioni da un componente all'altro

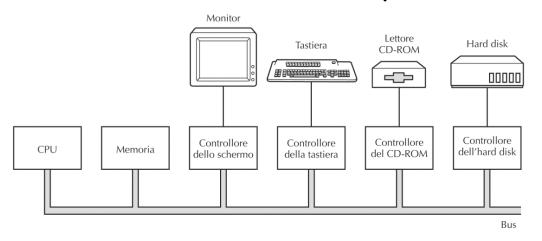
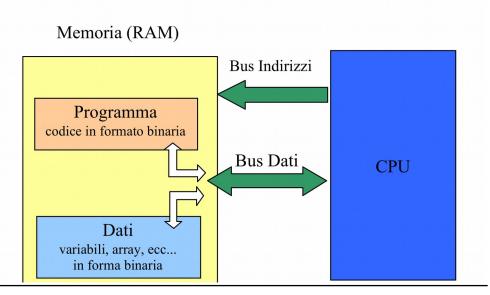


Figura 2.30 Struttura logica di un semplice personal computer.

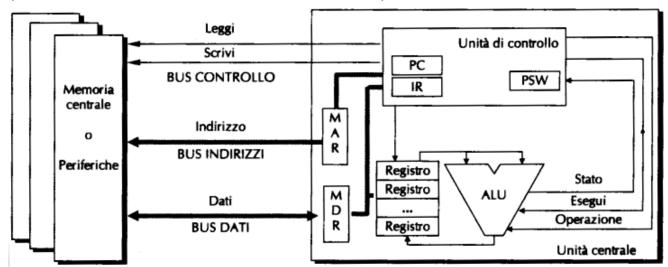
#### Architettura di Von Neumann

- Usa la memoria non solo per i dati ma anche per i programmi. Quando fu proposta era rivoluzionaria: evitava complesse configurazioni con interruttori e cavi
- Programmi e dati sono trasferiti entrambi attraverso il (sotto)bus dati. Il (sotto)bus indirizzi è utilizzato dalla CPU per indicare alla memoria le locazioni delle informazioni da trasferire



#### La CPU

- Esegue i programmi nella memoria centrale
- Una CPU è composta da:
  - Unità di controllo: legge e interpreta le istruzioni
  - ALU: esegue le operazioni (AND,OR, addizione, ...)
  - Registri: memorizzano i risultati temporanei e le informazioni necessarie al funzionamento



# La CPU - registri

- Alcuni registri speciali:
  - Program Counter (PC): indica la prossima istruzione in memoria
  - Instruction Register (IR): memorizza l'istruzione che si sta per eseguire
  - Memory Address Register (MAR): indirizzo della cella di memoria da usare nella prossima lettura/scrittura
  - Memory Data Register (MDR): registro che accede al Bus dei Dati (sia in lettura che in scrittura)
  - Program Status Word (PSW): indica informazioni sull'ultima operazione eseguita (zero, overflow, ...)

# La CPU – esecuzione di una (tipica) istruzione

- 1. contenuto di PC posto su MAR e attivazione linea Leggi
- 2. il contenuto in memoria all'indirizzo indicato da MAR viene scritto su MDR attraverso il bus dati
- 3. contenuto di MDR copiato su IR e relativa decodifica
- 4. l'istruzione passa in esecuzione sulla ALU
- 5. se ci sono operandi da prelevare in memoria, si collocano in registri (usando come sopra MAR e MDR)
- 6. terminata l'esecuzione il risultato va su registro destinazione; se bisogna scrivere in memoria il valore calcolato si usano MAR / MDR attivando linea Scrivi
- 7. Si ritorna al punto 1 dopo aver aggiornato il valore di PC

# Fetch – Decode – Execute (FDE)

- Il ciclo di esecuzione descritto nella slide precedente è conosciuto come ciclo "Fetch - Decode - Execute":
  - Caricamento (Fetch): acquisizione dalla memoria di un'istruzione del programma
  - Decodifica (Decode): identificazione del tipo di operazione da eseguire
  - Esecuzione (Execute): effettuazione delle operazioni corrispondenti all'istruzione
- In particolare: i passi 1-2 corrispondono a Fetch, il passo 3 a Decode, i passi 4-5-6 ad Execute

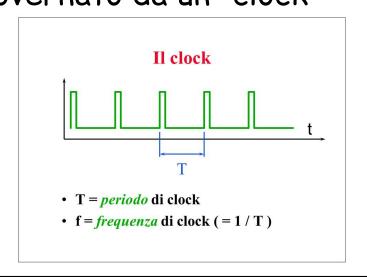
#### Facciamo uno zoom sull'Unità di Controllo

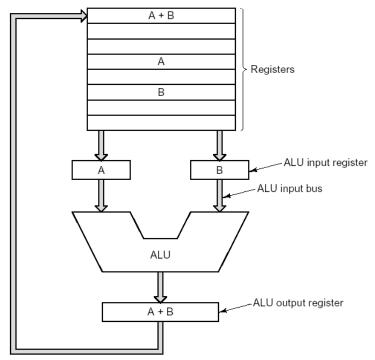
- Il modo più semplice per realizzare l'unità di controllo consiste nel costruirla come un circuito hardware compatibile con un insieme fissato di istruzioni
- Ciò diventa però complicato se l'insieme delle istruzioni è troppo grande; in tal caso, l'unità di controllo risulterebbe troppo costosa
- Una possibile risposta è permettere una (micro)programmazione del comportamento della CPU:
  - Si possono eseguire più istruzioni con i medesimi componenti
  - Cambiando il microprogramma cambia il comportamento della CPU (correzione errori, aggiunta di nuove istruzioni,...)

# Facciamo uno zoom sul modo di operare della ALU

- Con il termine Data Path (percorso dati) intendiamo la parte della CPU comprendente ALU, i suoi input ed i suoi output (solitamente registri)
- Il flusso da registri a ALU, scrittura dell'output register, e riscrittura in registro del risultato avviene durante il "ciclo di data path"

  governato da un "clock"





#### Velocità della CPU

- durata ciclo di data path =
   durata ciclo di clock =
   1 / F
   (dove F è la frequenza di lavoro della CPU; la frequenza viene
   misurata in Hertz Hz che indica il numero di cicli in un
   secondo)
- durata istruzione ISA (Instruction Set Architecture) = n × durata ciclo di data path
   (con n variabile da istruzione a istruzione a seconda della specifica architettura)
- Istruzioni ISA per secondo = 1 / durata istruzione ISA = F / n (assumendo n cicli per istruzione)

# Evoluzione delle frequenza di lavoro delle principali CPU Intel

Chip	Data	MHz	N. transistor	Memoria	Descrizione
4004	4/1971	0,108	2300	640	Primo microprocessore su un solo chip
8008	4/1972	0,108	3500	16 KB	Primo microprocessore a 8 bit
8080	4/1974	2	6000	64 KB	Prima CPU di uso generale su un solo chip
8086	6/1978	5-10	29.000	1 MB	Prima CPU a 16 bit su un solo chip
8088	6/1979	5-8	29.000	1 MB	Usato nel PC IBM
80286	2/1982	8-12	134.000	16 MB	Introduzione della modalità protetta
80386	10/1985	16-33	275.000	4 GB	Prima CPU a 32 bit
80486	4/1989	25-100	1,2 M	4 GB	Memoria cache da 8 KB integrata
Pentium	3/1993	60-233	3,1 M	4 GB	Due pipeline; istruzioni MMX nei modelli successivi
Pentium Pro	3/1995	150-200	5,5 M	4 GB	Cache integrata a due livelli
Pentium II	5/1997	233-450	7,5 M	4 GB	Pentium Pro con istruzioni MMX
Pentium III	2/1999	650-1400	9,5 M	4 GB	Istruzioni SSE per la grafica 3D
Pentium 4	11/2000	1300-3800	42 M	4 GB	Hyperthreading; ulteriori istruzioni SSE
Core Duo	1/2006	1600-3200	152 M	2 GB	Due core in un singolo circuito stampato
Core	7/2006	1200-3200	410 M	64 GB	Architettura quad-core a 64 bit
Core i7	1/2011	1100-3300	1160 M	24 GB	Processore grafico integrato

**Figura I.II** I membri principali della famiglia di CPU Intel. Le velocità del clock sono misurate in MHz (megahertz) dove I Mhz corrisponde a I milione di cicli/s.

#### Alla ricerca della velocità

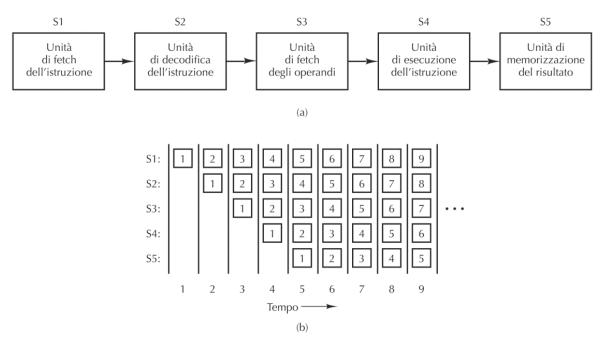
- Uno degli aspetti principali dell'evoluzione dei computer è stato l'aumento della velocità di calcolo
  - Molto più rapida dell'evoluzione in altri campi (ad esempio trasporti)
- Il ciclo di clock dipende in gran parte da motivazioni fisiche
  - Ma anche dalla complessità delle operazioni da eseguire
- Fissato il ciclo di clock si può aumentare la velocità aumentando il parallelismo

# RISC oppure CISC

- Alla fine degli anni '70, la microprogrammazione permise di realizzare elaboratori con istruzioni molto complesse: CISC - Complex Instruction Set Computer
- In contrapposizione a questa tendenza nacque l'idea di realizzare architetture con set di istruzioni più semplici: RISC - Reduced Instruction Set Computer
  - Istruzioni più semplici possono essere eseguite più velocemente (con un ciclo di clock ridotto)
  - Possibilmente evitando la microprogrammazione
- Ecco perché il livello che abbiamo chiamato "microarchitettura" può essere implementato tramite software (microprogrammazione) oppure hardware

# **Pipelining**

Un modo per migliorare le prestazioni di un processore è eseguire contemporaneamente più cicli FDE, usando per ognuno di essi parti diversi della CPU. Ad esempio potremmo immaginare 5 sezioni indipendenti:



**Figura 2.4** (a) Pipeline a cinque stadi. (b) Lo stato degli stadi in funzione del tempo. Sono mostrati nove cicli di clock.

#### Multicore

- In alcuni casi, all'interno della medesima CPU si replicano unità di controllo e ALU per esecuzioni di attività in parallelo
  - Tali architetture sono dette multicore

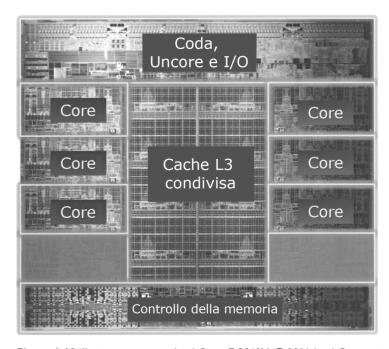
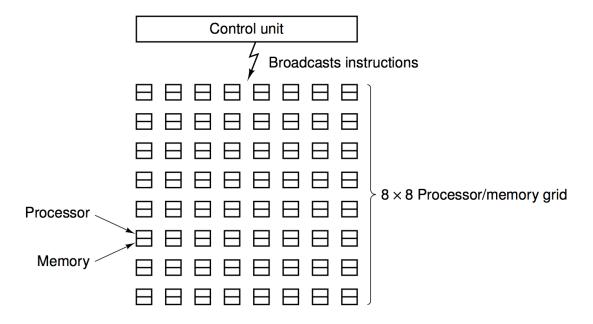


Figura 1.12 Il microprocessore Intel Core i7-3960X, © 2011 Intel Corporation. Il chip misura 21×21 mm² e contiene 2,27 miliardi di transistor (con "Uncore" si intendono le funzionalità esterne al core).

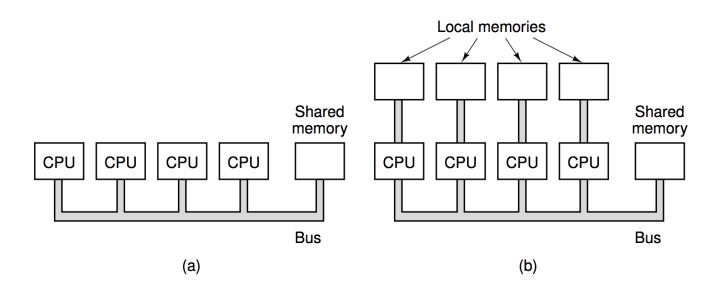
#### **Parallelismo**

- Ulteriori incrementi delle prestazioni si possono ottenere con molte CPU che lavorano in modo coordinato
- Un primo esempio è dato dagli "Array computer":
  - Processori eseguono la stessa istruzione su dati diversi
  - SIMD: single istruction-stream, multiple data-stream



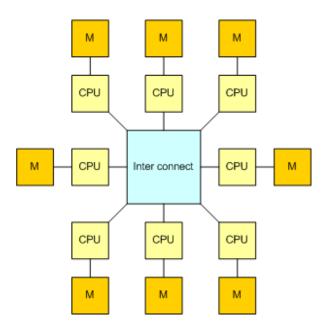
#### Parallelismo - continua

- Un altro esempio importante è quello dei multiprocessori
  - Molti processori anche diversi che condividono una memoria, senza eseguire necessariamente la stessa istruzione
  - MIMD: multiple istruction-stream, multiple data-stream.



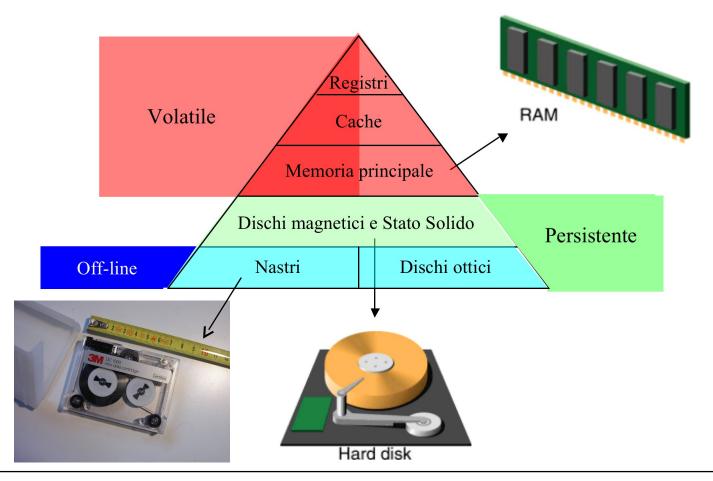
#### Parallelismo - continua

- Infine, si possono avere i multicomputer, la forma più estrema di parallelismo..
  - Molti processori che non condividono una memoria e che comunicano scambiandosi dei messaggi
  - Si può fare in modo che moltissime CPU cooperino



#### Le memorie

Le memorie sono le componenti del calcolatore in grado di memorizzare le informazioni: dati, programmi e risultati indispensabili per il suo funzionamento



#### Le memorie

- Si usano vari tipi di memoria diversi per scopi diversi:
  - Volatile: l'informazione rimane memorizzata fino a che il calcolatore è alimentato
  - Persistente: l'informazione rimane memorizzata anche quando il calcolatore non è alimentato (spento)
  - On-line: i dati sono sempre accessibili
  - Off-line: il supporto deve essere montato per poter accedere ai dati
- Il costo di memorizzazione per byte cresce salendo la piramide
- La capacità (q.tà di byte) cresce scendendo la piramide

# Organizzazione delle memorie

- Le memorie si organizzano in celle
  - Una cella è una sequenza di bit con un suo specifico indirizzo

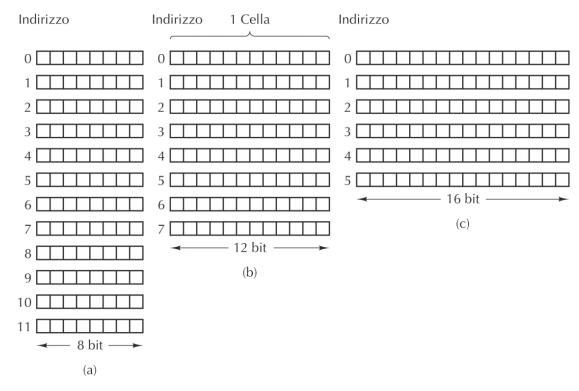


Figura 2.9 Tre modi di organizzare una memoria a 96 bit.

# Perché byte... e quanto valgono i Kbyte, Mbyte,...

- Un bit è una informazione binaria (0 oppure 1)
- Negli anni '60, con l'avvento dell'IBM 360, emerse l'abitudine di organizzare le memorie in celle da 8 bit, i cosiddetti "byte"
- Il Kbyte coincide con la capacità di memorizzazione di una memoria con celle da 8 bit, indirizzabile con indirizzi a 10 bit

Nome	Significato			
Bit	cifra binaria			
Byte	8 bit			
KByte (KB)	$2^{10}~(\sim 10^3)$ byte			
MByte (MB)	$2^{20}~(\sim 10^6)$ byte			
GByte (GB)	$2^{30}~(\sim 10^9)$ byte			
TByte (TB)	$2^{40}~(\sim 10^{12})~{ m byte}$			

# Ma a volte blocchi di 8 bit sono troppo piccoli...

- Molti calcolatori lavorano su blocchi di dimensione superiore ad 8 (ad esempio registri a 32 o 64 bit)
  - Tali blocchi vengono dette parole (in inglese "word")
- Esistono 2 modi per memorizzare le "word" in celle di memoria di dimensione standard (1 byte): big endian (indirizzi assegnati da sx a dx) e litte endian (opposto)

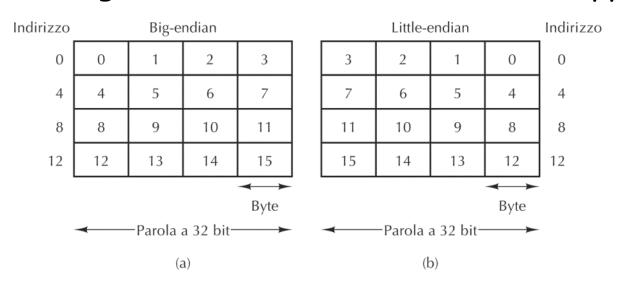
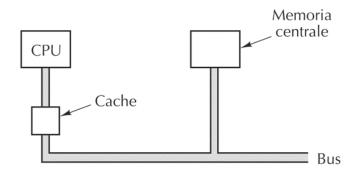


Figura 2.11 (a) Memoria big endian. (b) Memoria little endian.

#### Memoria cache

- La cache è una memoria poco capiente ma molto veloce
  - le parole di memoria usate più di frequente sono mantenute all'interno della cache
- Quando la CPU necessita di una parola, la cerca nella cache e se non è presente, la preleva dalla memoria
  - In tal caso il contenuto della memoria centrale viene trasferito nella cache



**Figura 2.16** Da un punto di vista logico la cache si trova tra la CPU e la memoria centrale. Fisicamente può essere collocata in varie posizioni.

#### Perché usare una cache

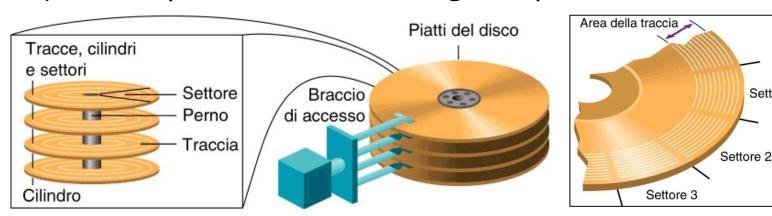
- La maggior parte dei programmi esibiscono il cosiddetto principio di località
  - Riferimenti alla memoria eseguiti a breve distanza di tempo sono spesso anche in locazioni vicine
- Si sfrutta il principio di località mettendo in cache blocchi di locazioni contigue, aumentando così la probabilità che successivi accessi alla memoria possano essere all'interno del blocco già trasferito
  - il guadagno dato dal più veloce accesso a dati già in cache è solitamente superiore al tempo perso per trasferire i blocchi da memoria a cache, e viceversa

# Quantificare l'impatto di una cache sulle prestazioni

- Supponiamo che
  - c sia il tempo di accesso alla memoria cache
  - m sia il tempo di accesso alla memoria centrale
  - h sia l'hit-ratio, cioé la frazione di riferimenti che può essere soddisfatta dalla cache
  - allora il tempo medio di accesso  $t \in c+(1-h)m$
- Quando h si avvicina a 1, il tempo medio t si avvicina a c, mentre quando h si avvicina a 0, t si avvicina a c+m

# Dischi magnetici

- Un hard disk (HD) è un dispositivo elettro-meccanico per la conservazione di informazioni sotto forma magnetica
  - Testina: magnetizza e legge lo stato di magnetizzazione della superficie del disco
  - Traccia: sequenza circolare di bit
  - Settore: porzione di traccia che contiene una quantità prefissata di bit (uguale per tutti i settori)

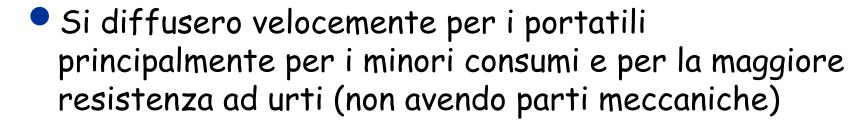


Settore

#### Memorie allo stato solido

Si tratta di dispositivi completamente elettronici, senza nessuna parte in movimento.

 La comune denominazione "disco allo stato solido" è pertanto inadeguata



- Più veloci ma meno capienti dei dischi rigidi (ordine dei 200 GB contro ordine dei TB)
- Tecnologia simile alle chiavette USB, ma più elaborata

SanDisk

SSD

**32GB** 

# RAID (Redundant Array of Inexpensive Disks)

- La differenza nelle prestazioni delle CPU e dei dischi magnetici aumenta continuamente
- Per ridurre tale gap, e per migliorare la affidabilità dei dischi, la tecnica RAID utilizza in parallelo più dischi
  - Più veloce perché si leggono più dati contemporaneamente, più affidabile se si replicano i dati e si aggiungono bit di controllo per verificare/correggere errori
- Esistono diversi modi per usare i vari dischi in parallelo

# RAID (Redundant Array of Inexpensive Disks) - continua

- Non-redundant data striping
- Redundant data striping
- Data striping at bit level
- Bit-interleaved parity
- Block-interleaved parity
- Block-interleaved distributed parity

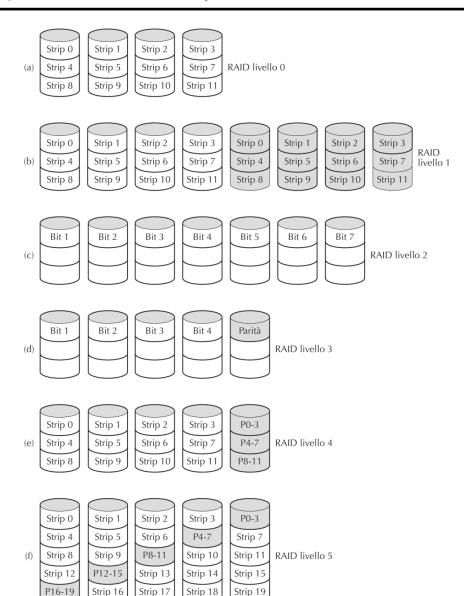


Figura 2.23 RAID dal livello 0 al livello 5. I dischi di backup e di parità sono in grigio.

#### Dischi ottici

- I CD (Compact Disc) utilizzano un principio ottico
  - Informazioni codificate tramite fori (Pit) alternati con zone piane (Land)
  - Un passaggio Pit-Land o Land-Pit codifica un 1
  - L'assenza di variazioni codifica lo 0
  - Le informazioni sono lette tramite un raggio laser che viene riflesso diversamente al passaggio su pit e land

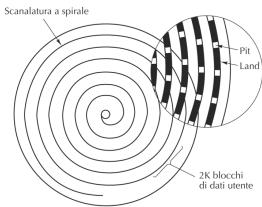


Figura 2.25 Struttura di registrazione di Compact Disc e CD-ROM.

# Tipi di dischi ottici

- CD-ROM: scritti dal costruttore (Read Only Memory)
- CD-R o CD Registrabili: scrivibili una sola volta
- CD-RW: ri-scrivibili più volte
- DVD: Digital Video Disk o Digital Versatile Disk
- Blu Ray: laser blu e non rosso (diversa frequenza)

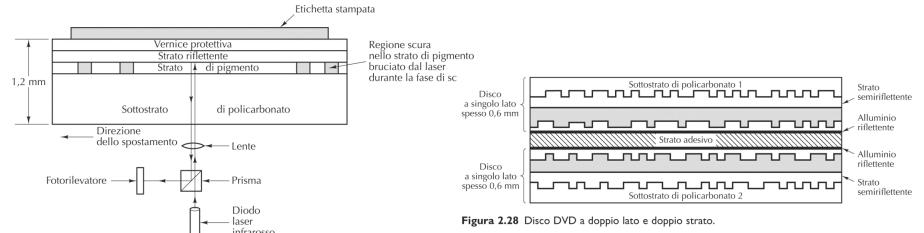


Figura 2.27 Spaccato di un disco CD-R e del laser (non in scala). La struttura di un CD-ROM è simile, fatta eccezione per la mancanza dello strato di pigmento e per la presenza di uno strato di alluminio con pit al posto dello strato riflettente.

#### Oltre le memorie

- Oltre le memorie, i calcolatori includono altri componenti quali, ad esempio:
  - Tastiera, mouse
  - Monitor: richiede una specifica scheda video che contiene un proprio processore detto GPU (Graphical Processing Unit)
    - Solitamente basate su architetture multicore estremamente avanzate
    - Programmabili (tramite specifici linguaggi, quali Cuda-C) per eseguire programmi non grafici
  - Stampanti
  - Schede di rete (wifi, bluetooth, ethernet, modem, ...)

# Il calcolatore è quindi un sistema che combina varie componenti

- Come abbiamo già visto le componenti del calcolatore sono fra loro collegate tramite bus
  - I dispositivi si collegano al bus tramite un "controller"
  - Alcuni controller accedono direttamente alla memoria
    - Tecnica detta DMA (direct memory access)
    - Al termine della scrittura/lettura si invia un segnale (interrupt) alla CPU
  - L'accesso al bus condiviso viene gestito da un "arbitro" del bus
  - PCI-X, PCI, SCSI, ISA,... sono tipi di bus